

文本情感分析在金融中的应用

金融数据分析与建模·小组作业

小组成员：谢婧怡、梁柏麟、黄彦琦、郭虹辰、黄丽蓉

日期：2026 年 3 月

中山大学岭南学院

目录

1. 动机与问题
2. 方法原理
3. Python实现
4. 金融应用场景
5. 方法对比
6. 局限性与注意事项
7. 学习反思
8. 参考资料

动机：这个方法解决什么问题？

动机：文本情感分析将非结构化的文本信息（新闻、财报、社交媒体）转化为结构化的情感信号，解决了传统量化模型只看数字、忽略市场情绪的问题。

不用文本情感分析会出现的错误

- **信息丢失**：只看结构化数据（价格、财务指标），忽略占市场信息 **80%** 以上的文本内容
- **反应滞后**：无法实时捕捉市场情绪变化
- **粒度粗糙**：只能看到"股价跌了5%"，但看不到**"在股价跌5%的前一天，社交媒体负面情绪已飙升80%"**

核心原理

方法步骤（以词典法为例）

Step 1: 文本预处理

- 去除标点符号和特殊字符
- 中文分词 (jieba) / 英文分词 (nltk)
- 过滤停用词和单字词

Step 2: 情感词典匹配

- 统计正面词（增长、盈利）和负面词（下跌、亏损）
- 考虑否定词对情感极性的反转作用
- 可选择加入程度副词对情感强度进行加权

Step 3: 情感得分计算

- 净得分 = 正面词数 - 负面词数
- 归一化得分 = 净得分 / 总词数

关键公式

F1 分数（分类评估）

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

其中：

- Precision（精确率）= 预测为该类别且正确的数量 / 预测为该类的总数量
- Recall（召回率）= 预测为该类别且正确的数量 / 实际为该类的总数量

词典法归一化情感得分

$$\text{NormalizedScore} = \frac{\text{PosCount} - \text{NegCount}}{\text{TotalWords}}$$

核心假设

假设	说明	违反假设的后果
词袋假设	词语的顺序不影响情感，只关注词频	无法处理转折句、否定词的范围等复杂结构
领域一致性	情感词在不同语境下极性相同	通用词典在金融领域失效（如"风险"在风控中是中性词）
情感独立	每个文本的情感判断独立于其他文本	忽略事件的时序依赖和市场预期的累积效应

Python实现：词典法核心代码

```
import jieba
import re

# 金融情感词典 (简化示例)
positive_words = set(['增长', '盈利', '强劲', '超预期'])
negative_words = set(['下跌', '亏损', '风险', '疲软'])
negation_words = set(['不', '并非', '并未', '没有'])

def preprocess_text(text):
    text = re.sub(r'^\u4e00-\u9fa5', ' ', text)
    words = jieba.lcut(text)
    return [w for w in words if len(w) > 1]

def sentiment_score(words):
    pos = sum(1 for w in words if w in positive_words)
    neg = sum(1 for w in words if w in negative_words)
    # 否定词处理: 检查前一个词是否是否定词...
    return (pos - neg) / len(words)

关键参数: 使用 negation_words 处理"并未改善"这类否定结构
```

金融应用场景

场景1：量化交易策略 - 基于新闻情感的择时与选股

问题：市场对新闻的反应迅速且过度，传统模型无法实时捕捉。

方法：使用 FinBERT 对实时新闻流进行情感分类或连续得分预测；当情感得分超过阈值时买入，低于阈值时卖出

价值：回测显示基于新闻情感的策略可获得显著超额收益，尤其在高频交易和事件驱动策略中。

场景2：风险管理与危机预警 - 负面舆情监测

问题：突发负面新闻（高管丑闻、监管调查）引发股价暴跌，传统风险模型滞后。

方法：构建情感监测系统，使用词典法或微调模型实时扫描社交媒体、新闻、监管文件；设置预警阈值，负面情感强度超过水平或急剧下降时发出警报；触发仓位调整或暂停交易

价值：帮助机构规避"黑天鹅"事件，减少回撤。例如瑞幸咖啡造假事件爆发前，社交媒体情感已异常负面。

与相关方法的对比

文本情感分析 vs 主题建模

维度	文本情感分析	主题建模 (LDA/BERTopic)
核心目标	判断"情绪如何" (正面/负面/中性)	发现"在讨论什么" (话题聚类)
输出	情感标签或连续得分	话题分布、话题关键词
典型技术	词典法、FinBERT 微调、LLM 提示	LDA、NMF、BERTopic
金融应用	交易信号、风险预警	财报电话会议话题分析、热点追踪

互补关系：两者常结合使用：先分话题，再在每个话题内做情感分析

篇章级情感分析 vs 方面级情感分析

维度	篇章级情感分析	方面级情感分析 (ABSA)
粒度	整篇文章一个情感得分	针对特定方面 (如"营收"、"现金流") 分别判断
信息损失	高: "先夸后骂"可能被判中性	低: 保留细粒度信息
技术复杂度	低: 分类/回归即可	高: 需要方面抽取 + 情感分类
金融实用性	基础: 适合快速原型	最佳: 可构建多维度因子

局限性与注意事项

方法本身的假设局限	说明
领域依赖性强	通用词典在金融领域表现糟糕，需使用 Loughran-McDonald 等专业词典
复杂语言现象处理有限	反讽、双重否定、条件假设仍具挑战（但金融严肃文本中反讽罕见）
缺乏外部知识	模型仅基于文本，无法利用行业背景、公司历史等常识
长文本限制	BERT 等模型有 512 token 输入限制，处理 10-K 年报需截断或分层

实践中常见问题	避坑建议
用准确率评估不平衡数据	金融文本 80% 以上是中性，应监控宏平均 F1、MCC
随机划分造成时间泄露	必须按时间顺序划分：训练集早于验证集，验证集早于测试集
过度调优验证集	避免在验证集上反复调参，最终用独立测试集评估
将相关性误认为因果性	情感与价格相关，但方向难定，需用格兰杰因果检验
忽略模型不确定性	输出概率或置信区间，仅在高置信度时交易
使用通用词典未验证	使用 Loughran-McDonald 金融词典，或在金融语料上微调

学习反思：AI哪里不准确？走了哪些弯路？

1. AI回答不准确之处

第3轮代码错误：AI最初提供的否定词处理代码存在逻辑错误（赋值语句`neg_count += 1`位置错误），实际运行时报错。通过调试发现后，第4轮修正。

第8轮过度深入：讨论checkpoint选择时，AI引入过多进阶指标（IC、夏普比率），对初学者过于复杂，及时切换话题。

2. 学习过程中的弯路

初期想一步上大模型：最初想直接用FinBERT微调，但对预训练-微调范式理解不足。纠正：回头先搞懂词典法，再逐步深入。

忽略了分类vs回归的选择：一开始未明确任务类型，后来通过第9-10轮对话才理清两者区别。

3. 尚未搞清楚的问题

方面级情感分析的具体实现：如何用BERT+CRF同时抽取方面词并判断情感？

金融领域长文本处理：10-K年报远超512 token，层次化模型如何实现？

参考资料

学术论文

1. Loughran and McDonald (2011)

"When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks"
The Journal of Finance, Vol. 66, No. 1.
(构建了金融领域权威情感词典)

2. Tetlock (2007)

"Giving Content to Investor Sentiment: The Role of Media in the Stock Market"
Journal of Finance, Vol. 62, No. 3.
(开创性研究媒体情感与股票收益的关系)

3. Araci (2019)

"FinBERT: Financial Sentiment Analysis with Pre-trained Language Models"
arXiv:1908.10063
(金融领域预训练模型 FinBERT)

GitHub 仓库

仓库	说明	链接
FinBERT	金融情感分析预训练模型	https://github.com/ProsusAI/finbert
Loughran-McDonald Dictionary	金融情感词典官方资源	https://sraf.nd.edu/loughranmcdonald-master-dictionary/
Transformers	Hugging Face 预训练模型库	https://github.com/huggingface/transformers